Paper research:

Video-RAG: Visually-aligned Retrieval-Augmented Long Video Comprehension

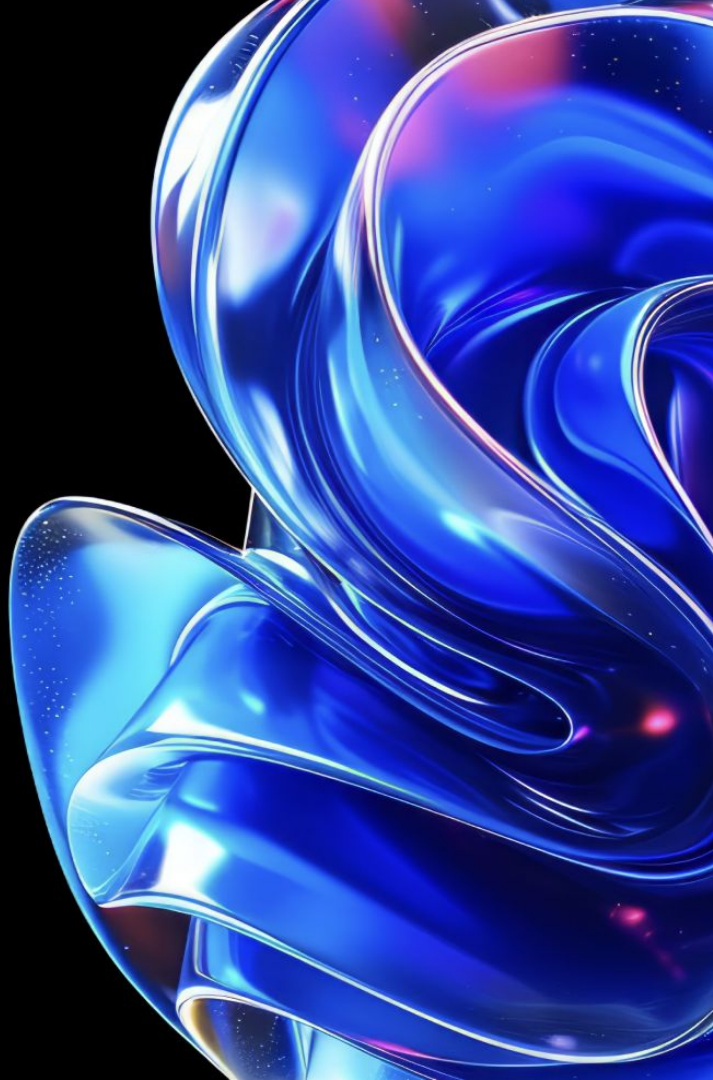

Макс Ляра
Валерия Кущенко
4 курс ОЭ ЭМИТ

16 апреля 2026

Paper analysis

01 —

Краткая сводка по статье

Проблема

LVLM плохо справляются со своей задачей - вдруг мы закинем в любую из них видео по тому, как готовить самый прекрасный кулич на свете, а они не смогут объяснить нам, какую граммовку нужно использовать?... или какой крем лучше всего подходит для шапочки?.. или какую именно муку нужно выбрать?..

В общем, нужно придумать, как научить нейронки “слышать”, “видеть” и “читать” картинки одновременно. Еще будет круто научить их делать это не с одним видео, а сразу с несколькими

Пайплайн из статьи

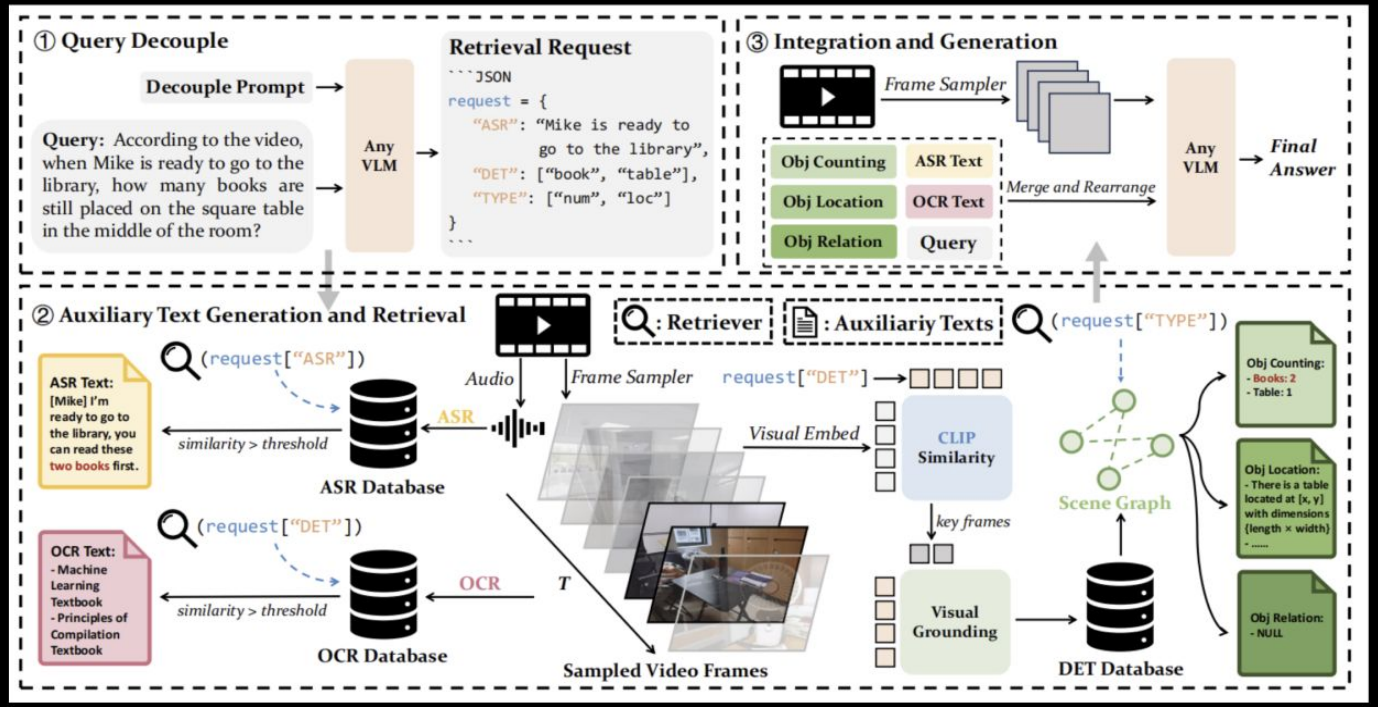

16 апреля 2026

Paper analysis

Выводы статьи

Model	Params	Frames	Short			Medium			Long			Overall			Gain
			w/o S	w/ S	Ours	w/o S	w/ S	Ours	w/o S	w/ S	Ours	w/o S	w/ S	Ours	
Proprietary LVLMs															
GPT-4o [29]	-	384	80.0	82.8	-	70.3	76.6	-	65.3	72.1	-	71.9	77.2	-	-
Gemini-1.5-Pro [32]	-	0.5 fps	81.7	84.5	-	74.3	81.0	-	67.4	77.4	-	75.0	81.3	-	-
Open-Source LVLMs															
Video-LLaVA [18]	7B	8	45.3	46.1	49.5	38.0	40.7	43.0	36.2	38.1	42.5	39.9	41.6	45.0	+3.4
LLaVA-NeXT-Video [51]	7B	16	49.4	51.8	56.6	43.0	46.4	47.4	36.7	44.9	46.0	43.0	47.7	50.0	+2.3
VITA-1.5 [7]	7B	16	67.0	69.9	71.0	54.2	55.7	55.4	47.1	50.4	52.4	56.1	58.7	59.6	+0.9
LongVA [49]	7B	128	61.1	61.2	66.1	50.4	53.8	60.4	46.2	52.9	59.4	52.6	56.0	62.0	+6.0
Long-LLaVA [45]	7B	64	61.9	62.4	67.1	51.4	56.2	60.4	45.4	54.7	60.1	52.9	57.8	62.6	+4.8
Qwen2-VL [40]	72B	32	75.0	76.7	77.4	63.3	69.9	70.2	56.3	69.2	71.0	64.9	71.9	72.9	+1.0
LLaVA-Video [52]	72B	64	80.7	81.8	82.8	68.7	73.8	76.3	62.1	72.2	73.1	70.3	75.9	77.4	+1.5

бежит бороться за видео раги

16 апреля 2026

Paper analysis

Наша адаптация статьи

Адаптированный пайплайн

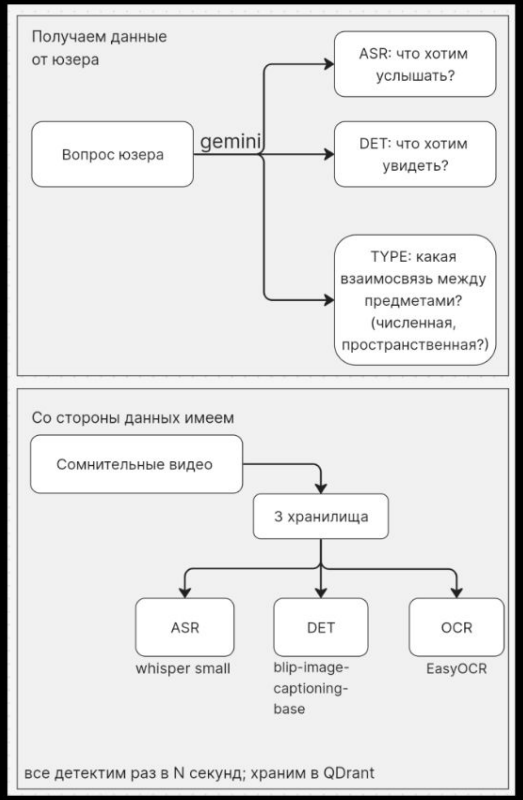

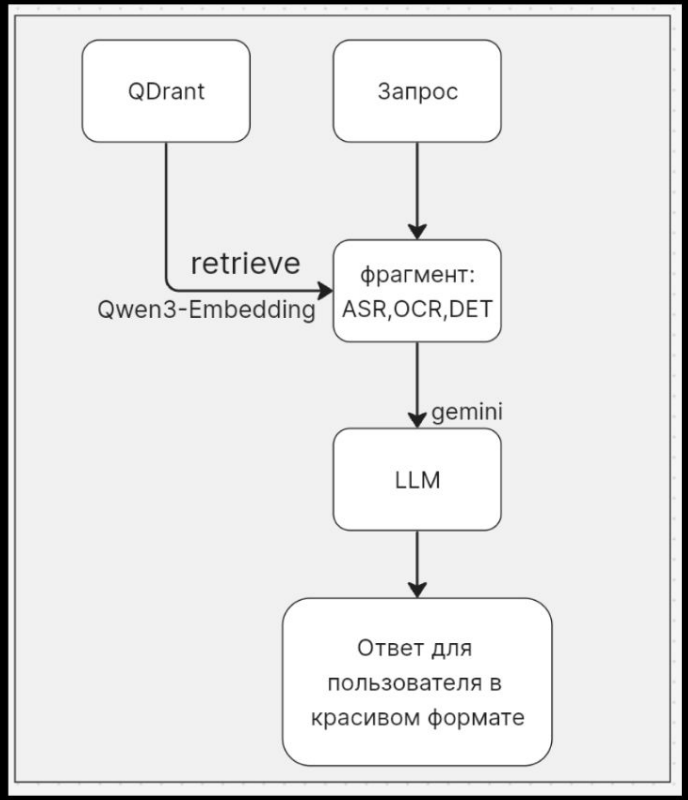

Пример ответа:
Ответ: В видео про Roblox говорят в самом начале, обсуждая его блокировку в России, а также в середине ролика при вводе поискового запроса и проверке работоспособности игры.
Фрагмент: roblox.mp4, 00:00-01:01, В интервале 00:00-00:08 автор сообщает о блокировке Roblox Роскомнадзором. В 00:17-00:22 он диктует поисковый запрос «Роблокс – YouTube – Запрет», а на 00:56-01:01 подтверждает вход в игру после обхода блокировки.

ASR модуль

Данный модуль основан на работе ASR модели whisper small (легкая и быстрая). Реализация простая - моделька просто слушает речь и преобразует ее в текст

Также она умеет автоматически переводить услышанное и фиксирует вероятность тишины (no_speech_prob). Если она высокая - оставляем пустоту

Грустный пример:

```
[ASR]
Роблок запретили в России. Я думаю, нелегкого не секрет, что наш всеми любимый
Роблок заблокировали Роскомнадзор. Но не переживайте, это еще не конец, ведь
покажу в этом видео. Для начала заходим по ссылке в описании, либо же вводим в
своем браузере «Роблокс — YouTube — Запрет». Переходим в гитхаб и дальше
```

С точки зрения скорости/качества остановились на small модельке - по сравнению с tiny она лучше распознает речь, а по сравнению с medium - быстрее

OCR модуль

В данном модуле все довольно просто.
Берем модельку EasyOCR, “считываем” ею текст с кадра раз в N секунд.

Для улучшения “чтения” - увеличиваем контраст.
Включаем распознание на eng+ru языках.

Получаем подобный формат:

```
[OCR]
ОБХОд | БЛОКИРОВКИ
Роблокс ютуб запрет] | Роблокс ютуб запрет | Яндексе | скачать запрет дискорд ютуб роблокс
локс дискорд | Jапрет Дискорд ютуб роблокс скачать
```

DET модуль

Делим все выходящие из detection-части логически:

В сыром виде раз в N секунд мы получаем что-то вроде:
“woman sitting at a table with a cup”

→ у нас есть субъект (кто)
→ у нас есть объект (что)
→ у нас есть действие (что происходит)
→ и даже есть пространственное отношение (где)

Для построения:
Глагол → ищем объект и субъект (кто делает, что делает)

Предложные связи: существительное → предлог → существительное → получаем relations из начала пайплайна

Допом подсчитываем количество слов

```
[DET]
a computer screen with a black screen
Object counting:
- computer: 1
- screen: 2
Detected objects:
- Object 0 is a computer
- Object 1 is a screen
a large screen with many different video games
Object counting:
- screen: 1
- video: 1
- game: 1
Detected objects:
- Object 0 is a screen
- Object 1 is a video
- Object 2 is a game
```

Работа модели

Какой творог больше подходит для сырников?

Ответ: Для идеальных сырников лучше всего подходит мягкий и, самое главное, сухой творог. Если творог жестковат, его рекомендуется пробить блендером или протереть через сито. Чтобы добиться нужной сухости, творог следует предварительно отжать через марлю.

Фрагмент: sirniki.mp4, 00:21-00:40, В этом интервале автор видео дает рекомендации по выбору текстуры творога и объясняет необходимость его отжимания для получения сухого продукта.

Что делать после того как я сделала ямочку на галстуке?

Ответ: После того как вы сделали ямочку на галстуке (нажав указательным пальцем под узлом), следующим шагом нужно затянуть галстук как обычно, но не слишком туго.

Фрагмент: galstuk.mp4, 00:55-01:17, В этом интервале на шаге №6 показано создание ямочки, а на шаге №7 (01:03) дается инструкция затянуть галстук.

Работа модели

В какой температуре нужно хранить компост для шампиньонов?

Ответ: Компост для шампиньонов необходимо хранить при температуре от 15 до 20 градусов в течение 2–3 недель, пока он не побелеет.

Фрагмент: shampinioni.mp4, 00:58-01:05, в данном интервале автор озвучивает конкретные температурные условия и сроки хранения коробки с компостом.

20:43

Как наносить воск на обувь?

Ответ: Для нанесения воска на обувь необходимо выполнить следующие действия:
1. Нанести небольшое количество воска на полировочную салфетку.
2. Равномерно распределить воск по поверхности ботинка для создания глянцевого блеска.
3. С помощью жесткой щетки убрать излишки воска.

Фрагмент: obuv.mp4, 00:40-01:01, В этом интервале демонстрируется процесс нанесения воска с помощью салфетки и последующая обработка щеткой, что сопровождается соответствующими голосовыми инструкциями.

20:43

16 апреля 2026

Paper analysis

Работа модели

Тестим и картинку, и звук
Какого цвета была подкладка у бежевого пальто?

Ответ: Подкладка бежевого пальто выполнена в стиле милитари (камуфляжная расцветка).

Фрагмент: palto.mp4, 00:22-00:50, на интервале 00:25-00:28 ведущий демонстрирует внутреннюю часть пальто, где видна камуфляжная подкладка, а в интервале 00:58-01:03 (Кандидат 4) подтверждает, что это подкладка в стиле милитари.

20:45

16 апреля 2026

Paper analysis

Готовы ответить на ваши вопросы!